

Московский Государственный Технический Университет имени Н.Э.Баумана

Факультет Информатика и системы управления

Кафедра ИУ-5

«Системы обработки информации и управления»

Отчёт по Рубежному контролю № 1

Методы обработки данных

Выполнили стуленты группы ИУ-5

Шэнь Цюцзе 22М

Москва 2022г.

Номер вариант: 22 Номер задачи №1: 7 Номер задачи №2: 33

Дополнительные требования по группам: для произвольной колонки данных построить гистограмму.

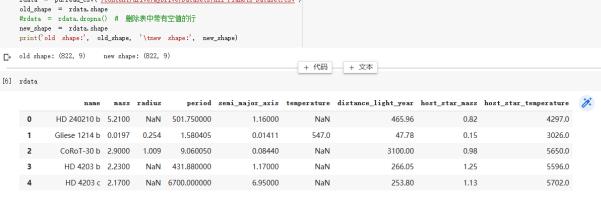
Задача №7: Для набора данных проведите устранение пропусков для одного (произвольного) числового признака с использованием метода заполнения медианой.

Задача №33: Для набора данных проведите процедуру отбора признаков (feature selection). Используйте метод обертывания (wrapper method), алгоритм полного перебора (exhaustive feature selection).

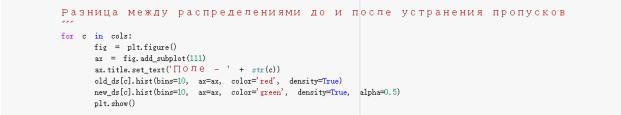
- Задача №7

import library and data

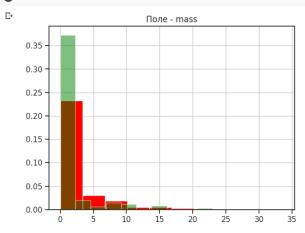
```
import numpy as np
     import pandas as pd
     import seaborn as sns
     import matplotlib.pyplot as plt
     import scipy.stats as stats
     from sklearn.svm import SVR
     from sklearn.svm import LinearSVC
     from sklearn.feature_selection import SelectFromModel
     from sklearn.linear_model import Lasso
     from sklearn.linear_model import LogisticRegression
     from sklearn.neighbors import KNeighborsClassifier
     from sklearn.neighbors import KNeighborsRegressor
     from sklearn.tree import DecisionTreeClassifier
     from sklearn.ensemble import RandomForestClassifier
     from sklearn.ensemble import GradientBoostingClassifier
     from sklearn.tree import DecisionTreeRegressor
     from sklearn.ensemble import RandomForestRegressor
     from sklearn.ensemble import GradientBoostingRegressor
     from sklearn.metrics import mean_squared_error
     from sklearn.model_selection import train_test_split
     from sklearn.feature_selection import VarianceThreshold
     from sklearn.feature_selection import mutual_info_classif, mutual_info_regression
     from sklearn.feature_selection import SelectKBest, SelectPercentile
     from IPython.display import Image
     %matplotlib inline
     sns.set(style="ticks")
# Будем использовать только обучающую выборку
   rdata = pd.read_csv('/content/drive/MyDrive/DataSets/All-Planets-Dataset.csv')
   old_shape = rdata.shape
   #rdata = rdata.dropna() # 删除表中带有空值的行
```

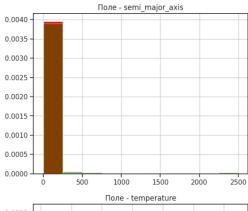


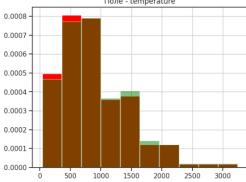
```
list(zip(rdata.columns, [i for i in rdata.dtypes]))
 [('name', dtype('0')),
      ('mame, drype('0')),
('mass', dtype('float64')),
('radius', dtype('float64')),
('period', dtype('float64')),
      ('semi_major_axis', dtype('float64')),
('temperature', dtype('float64')),
      ('distance_light_year', dtype('float64')),
      ('host_star_mass', dtype('float64')),
      ('host_star_temperature', dtype('float64'))]
[8] # 找出带有空值的列
     hcols_with_na
     ['mass',
       'radius',
      'period',
      'semi_major_axis',
      'temperature',
      'distance_light_year',
      'host_star_mass',
      'host_star_temperature']
[9] rdata.shape
     (822, 9)
[10] # 统计每一列的空值数量
     [(c, rdata[c].isnull().sum()) for c in hcols_with_na]
     [('mass', 44),
('radius', 627),
      ('period', 21),
      ('semi_major_axis', 42),
      ('temperature', 640),
      ('distance_light_year', 11),
      ('host_star_mass', 18),
      ('host_star_temperature', 31)]
```

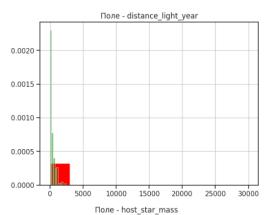


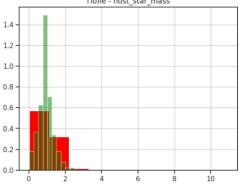
plot_hist_diff(rdata[rcols_intersted], rdata_drop, rcols_intersted)

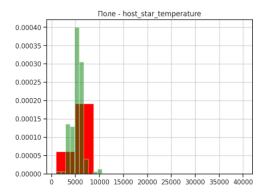












Задача №33

алгоритм полного перебора (exhaustive feature selection)

```
↑ ↓ ፡> 🗏 🛊 🗓 👔 :
pip install -U mlxtend
[28] from sklearn.datasets import make_classification
from sklearn.neighbors import KNeighborsClassifier
from mlxtend.feature_selection import ExhaustiveFeatureSelector as EFS
      # 生成二分类数据集
X, y = make_classification(n_samples=100, n_features=6, n_informative=3, n_redundant=0, random_state=42)
       # 定义KNN分类器
knn = KNeighborsClassifier(n_neighbors=3)
        # 定义特征选择器
efs = EFS(knn,
                                  min_features=2,
max_features=4,
scoring='accuracy',
print_progress=True,
        # 进行特征选择
efs = efs.fit(X, y)
       # 輸出结果
print('Best accuracy score: %.2f' % efs.best_score_)
print('Best subset (indices):', efs.best_idx_)
print('Best subset (corresponding names):', [f'Feature {idx+1}' for idx in efs.best_idx_])
```

Features: 50/50Best accuracy score: 0.90
Best subset (indices): (0, 3)
Best subset (corresponding names): ['Feature 1', 'Feature 4']